

Конспектировал: Всеволод Овечкин

1. МНК без теории вероятности

Регрессионный анализ используют в основном для:

1. описания зависимости между признаками
2. предсказания значений переменной

В этом семинаре речь пойдет о методе наименьших квадратов (МНК) без теории вероятности, решении задачи поиска коэффициентов различными способами и геометрической интерпретации МНК.

1.1. Пример выявления зависимости

Рассмотрим небольшой пример, в котором y - это количество составленных задач по эконометрике, x - это количество съеденных пирожков. Попробуем выяснить как зависят эти две величины.

y	x
10	5
14	6
5	2

Таблица 1: Зависимость количества составленных задач по эконометрике от количества съеденных пирожков.

Введем обозначения y_i - фактическое значение объясняемой переменной, \hat{y}_i - предсказанное значение объясняемой переменной, \hat{u}_i - ошибка предсказания.

$$y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}; \hat{y} = \begin{bmatrix} \hat{y}_1 \\ \hat{y}_2 \\ \vdots \\ \hat{y}_n \end{bmatrix}; \hat{u}_i = y_i - \hat{y}_i; \hat{u} = \begin{bmatrix} \hat{u}_1 \\ \hat{u}_2 \\ \vdots \\ \hat{u}_n \end{bmatrix}$$

Предположим, что зависимость выглядит следующим образом

$$\hat{y}_i = \hat{\beta} x_i$$

Как найти $\hat{\beta}$? МНК метод позволяет найти такую $\hat{\beta}$, чтобы сумма квадратов ошибок была минимальна. Математически эту идею можно выразить несколькими способами:

$$\sum_{i=1}^n (y_i - \hat{y}_i)^2 \rightarrow \min_{\hat{\beta}}$$

$$d^2(y, \hat{y}) \rightarrow \min_{\hat{\beta}}$$

$$(y - \hat{y})^T (y - \hat{y}) \rightarrow \min_{\hat{\beta}}$$

Решим задачу минимизации суммы:

$$Q(\hat{\beta}) = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n (y_i - \hat{\beta}x_i)^2 = \sum_{i=1}^n (y_i - 2y_i\hat{\beta}x_i + (\hat{\beta}x_i)^2) \rightarrow \min_{\hat{\beta}}$$

$$Q'(\hat{\beta}) = \sum_{i=1}^n (-2y_ix_i + 2\hat{\beta}x_i)$$

Найдем условие первого порядка:

$$\sum_{i=1}^n (-2y_ix_i + 2\hat{\beta}x_i) = 0$$

$$-2 \sum_{i=1}^n y_ix_i + 2\hat{\beta} \sum_{i=1}^n x_i = 0$$

$$\hat{\beta} = \frac{\sum_{i=1}^n y_ix_i}{\sum_{i=1}^n x_i}$$

$$\hat{\beta} = \frac{50 + 84 + 10}{25 + 36 + 4} = 2.215$$

Таким образом уравнение, позволяющее описать линейную зависимость y от x , и минимизирующее сумму квадратов остатков, выглядит следующим образом:

$$\hat{y} = 2.215 * x$$

1.2. Матричное дифференцирование

Пусть есть:

$$F = \begin{bmatrix} x_1 + x_2 & 2x_1^2 \\ x_1x_2 & \cos(x_2) \end{bmatrix}$$

Тогда:

$$dF = \begin{bmatrix} dx_1 + dx_2 & 4x_1dx_1 \\ x_1dx_1 + x_2dx_2 & -\sin(x_2)dx_2 \end{bmatrix}$$

Скаляр	Матрица
$d(a + b) = da + db$	$d(A + B) = dA + dB$
$d(ab) = bda + adb$	$d(AB) = dAB + AdB$
$d(cb) = cdb, c = const$	$d(CB) = CdB, C = const$
	$d(A^T) = (dA)^T$

Таблица 2: Сравнение операций дифференцирования скаляра и матрицы

Задачу поиска $\hat{\beta}$ так же можно решить при помощи матричного дифференциала:

$$Q(\hat{\beta}) = (y - \hat{y})^T (y - \hat{y}) \rightarrow \min_{\hat{\beta}}$$

$$\begin{aligned} dQ(\hat{\beta}) &= d(y - x\hat{\beta})^T(y - x\hat{\beta}) + (y - x\hat{\beta})^T d(y - x\hat{\beta}) = \\ &= (-xd\hat{\beta})^T(y - x\hat{\beta}) + (y - x\hat{\beta})^T(-xd\hat{\beta}) = \\ &= -2(y - x\hat{\beta})^T(xd\hat{\beta}) \end{aligned}$$

Найдем условие первого порядка. Так как для любого $d\hat{\beta}$ должно выполняться $dQ() = 0$, то

$$\begin{aligned} -2(y - x\hat{\beta})^T x &= 0 \\ x^T(y - x\hat{\beta}) &= 0 \\ x^T y - x^T x \hat{\beta} &= 0 \\ x^T x \hat{\beta} &= x^T y \\ \hat{\beta} &= \frac{x^T y}{x^T x} \end{aligned}$$

1.3. Упражнения на матричное дифференцирование

Найти dA^{-1} , зная

$$I_{n,n} = \begin{bmatrix} 1 & 0 & \dots & 0 \\ 0 & 1 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & 1 \end{bmatrix}; dI = 0; dA$$

Решение:

$$\begin{aligned} dI &= d(AA^{-1}) = dAA^{-1} + AdA^{-1} = 0 \\ dAA^{-1} &= -AdA^{-1} \\ dA^{-1} &= -A^{-1}dA \end{aligned}$$

2. МНК с несколькими регрессорами

Пусть имеются данные:

y	x	z
\vdots	\vdots	\vdots

Таблица 3: Случайные данные

Предположим, что мы хотим оценить уравнение регрессии:

$$\hat{y}_i = \hat{\beta}_1 + \hat{\beta}_2 x_i + \hat{\beta}_3 z_i$$

Введем обозначения: k - количество коэффициентов, n - количество наблюдений. Тогда

$$y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}; \hat{y} = \begin{bmatrix} \hat{y}_1 \\ \hat{y}_2 \\ \vdots \\ \hat{y}_n \end{bmatrix}; X = \begin{bmatrix} 1 & x_1 & z_1 \\ 1 & x_2 & z_2 \\ \vdots & \vdots & \vdots \\ 1 & x_n & z_n \end{bmatrix}; \hat{\beta} = \begin{bmatrix} \hat{\beta}_1 \\ \hat{\beta}_2 \\ \hat{\beta}_3 \end{bmatrix}$$

Уравнение регрессии можно записать в виде:

$$\hat{y} = X\hat{\beta}$$

Найдем методом МНК вектор $\hat{\beta}$:

$$\begin{aligned} dQ(\hat{\beta}) &= d(y - X\hat{\beta})^T(y - X\hat{\beta}) + (y - X\hat{\beta})^T d(y - X\hat{\beta}) = \\ &= (-Xd\hat{\beta})^T(y - X\hat{\beta}) + (y - X\hat{\beta})^T(-Xd\hat{\beta}) = \\ &= -2(y - X\hat{\beta})^T(Xd\hat{\beta}) \end{aligned}$$

Найдем условие первого порядка. Так как для любого $d\hat{\beta}$ должно выполняться $dQ() = 0$, то

$$\begin{aligned} -2(y - X\hat{\beta})^T X &= 0 \\ X^T(y - X\hat{\beta}) &= 0 \\ X^T y - X^T X\hat{\beta} &= 0 \\ X^T X\hat{\beta} &= X^T y \end{aligned}$$


В случае если $X^T X$ - обратима и $\det(X^T X) \neq 0$, то

$$\hat{\beta} = (X^T X)^{-1} X^T y$$

3. Геометрическая интерпретация МНК

$$\hat{Y} = \hat{\beta}_1 \bar{1} + \hat{\beta}_2 x$$


где, $\bar{1}$ - вектор столбец из единиц длины n . Описанное выше можно переформулировать следующим образом $\hat{y} \in \text{Lin}(\bar{1}, x)$. Или \hat{y} - проекция y на $\text{Lin}(\bar{1}, x)$



Так же из рисунка видно, что вектор ошибок \hat{u} перпендикулярен \hat{y} и подпространству $Lin(\bar{1}, x)$. Поэтому геометрический смысл условий первого порядка можно выразить следующим образом:

$$\begin{cases} \bar{1}\hat{u} = 0 \\ x^T \hat{u} = 0 \end{cases} \Leftrightarrow X^T \hat{u} = 0$$

4. Коэффициент детерминации. Геометрическая интерпретация



Возьмем тривиальную модель:

$$\hat{y} = \hat{\beta}_1 \bar{1}$$

В этой простой модели решение будет выглядеть следующим образом:

$$\hat{\beta} = \frac{\bar{1}^T y}{\bar{1}^T \bar{1}}$$

Тогда \hat{y} можно будет найти по формуле:

$$\hat{y} = \bar{1} * \frac{\bar{1}^T y}{\bar{1}^T \bar{1}} = \bar{1} * \frac{\sum y_i}{n} = \bar{1} * \bar{y}$$

где, \bar{y} - среднее значение y .

Вектор $\bar{1}\bar{y}$ на рисунке выше будет являть проекцией \hat{y} на вектор $\bar{1}$. А так как \hat{y} является проекцией y на пространство $Lin(\bar{1}, x)$, то вектор $\bar{1} * \bar{y}$ тоже будет являться проекцией y на вектор $\bar{1}$. Полученный треугольник с ребрами a , b , c является прямоугольным.

Предположим, что мы оцениваем какую-то линейную (не тривиальную) модель. Предсказанные значений y этой моделью обозначим как \hat{y} . Тогда стороны треугольника можно интерпретировать следующим образом:

- $\|b\|^2 = \sum_i (y_i - \bar{y})^2 = TSS$ (total sum of squares) - максимально возможная сумма квадратов ошибок модели при условии, что значения \hat{y} прогнозируются тривиальной моделью;
- $\|a\|^2 = \sum_i (y_i - \hat{y}_i)^2 = RSS$ (residual sum of squares) - остаточная сумма квадратов, являющаяся суммой квадратов ошибок (\hat{u}) модели;
- $\|c\|^2 = \sum_i (\hat{y}_i - \bar{y})^2 = ESS$ (explained sum of squares) - объясненная сумма квадратов, показывающая часть TSS, которую удалось объяснить моделью;

По теореме Пифагора получаем: $TSS = ESS + RSS$. Тогда то, на сколько лучше наша модель предсказывает y по сравнению с тривиальной моделью можно измерить коэффициентом детерминации:

$$R^2 = \frac{ESS}{TSS} = 1 - \frac{RSS}{TSS}; R^2 \in [0, 1]$$

Важное замечание: данная формула корректна в случае наличия $\bar{1}$ в модели.

5. Упражнения на проекцию вектора на линейное подпространство

Матрицей шляпницей будем называть матрицу, которая выполняет следующую функцию

$$Hy = \hat{y}$$

В задаче регрессии эта матрица является выражается через X

$$Hy = \hat{y} = X\hat{\beta} = X(X^Y X)^{-1}X^T y$$

$$H = X(X^Y X)^{-1}X^T$$

Чему равны следующие выражения:

1. $H^2 = ?$
2. $H^{2018} = ?$
3. $(I - H)^2 = ?$

Решение: 1-й пример это двойная проекция на $Lin(X)$, поэтому $H^2 = H$, так как проекция уже спроецированного вектора в $Lin(X)$ совпадает с этим вектором. 2-й пример решается ровно так же $H^{2018} = H$. В 3-м примере матрица $(I - H)$ является проекцией на ортогональное дополнение $Lin(X)$, т.е. проекция является вектором ошибок. Поэтому $(I - H)^2$ является двойной проекцией на ортогональное дополнение $Lin(X)$, т.е. $(I - H)^2 = (I - H)$

6. Геометрическая интерпретация транспонирования

Операцию транспонирования можно определить при помощи скалярного произведения не прибегая к фразе "переставление столбцов и строк местами".

Пусть есть 2 вектора x и y . Предположим над вектором x совершили преобразование A . Какое нужно совершить преобразование B над вектором y для того, чтобы выполнилось равенство:

$$\langle Ax, y \rangle = \langle x, By \rangle$$

Представим скалярное произведение в алгебраическом виде:

$$(Ax)^T y = x^T By$$

$$x^T A^T y = x^T By$$

Отсюда очевидно, что $B = A^T$.