

Конспектировала: Лиза Вахрамева.

## 1. О следе матрицы

Для квадратной матрицы  $A \in \mathbb{R}^{n \times n}$  вводится понятие следа матрицы:

$$\text{trace}(A) = \sum_{i=1}^n A_{ii},$$

то есть след матрицы — это сумма её диагональных элементов. След матрицы обладает следующими основными свойствами, мотивирующими его введение и дальнейшее использование:

1.  $\text{trace}(AB) = \text{trace}(BA)$ ,
2. след матрицы равен сумме корней характеристического уравнения,
3. след матрицы является скаляром:  $\text{trace}(\cdot) \in \mathbb{R}$ .

Покажем, что если у матрицы  $A$  есть  $n$  действительных собственных чисел  $\lambda_1 \dots \lambda_n$ , то  $\text{trace}(A) = \sum_{i=1}^n \lambda_i$ :

$$A = PDP^{-1},$$

где  $P$  — матрица, составленная из собственных векторов  $v_1 \dots v_n$ , соответствующих собственным числам  $\lambda_1 \dots \lambda_n$ , а матрица  $D$  — диагональная из собственных чисел:

$$\text{trace}(A) = \text{trace}(PDP^{-1}) = \text{trace}(DP^{-1}P) = \text{trace}(D) = \sum_{i=1}^n \lambda_i.$$

**Упражнение:** дана регрессия  $\hat{y} = X\hat{\beta}$ , построенная методом МНК по  $n$  наблюдениям,  $k$  регрессорам. Вектор наблюдений  $y$  можно спроецировать на пространство наблюдений  $\mathbb{R}^n$ , в котором строится предсказание, с помощью матрицы-шляпницы  $H$ :

$$\hat{y} = Hy.$$

Нужно найти  $\text{trace}(H)$ . Рассмотрим два возможных решения:

1. Содержательное.

Известно, что след  $H$  равен сумме собственных значений  $H$ . Также известно, что  $H$  проецирует вектора на линейную оболочку векторов-столбцов матрицы  $X$ , обозначим их  $c_1 \dots c_k \in \mathbb{R}^n$ . Так как всеобъемлющее пространство имеет размерность  $n$ , то набор  $c_1 \dots c_k$  векторов можно дополнить ортогональным набором  $p_1 \dots p_{n-k}$  до базиса. Все вектора  $c_1 \dots c_k$  переходят сами в себя при проекции, поэтому являются собственными с собственными числами 1. Все вектора  $p_1 \dots p_{n-k}$  являются ортогональными оболочке, на которую строится проекция, и при проекции переходят в ноль, поэтому они являются собственными векторами с собственными числами 0. Получилось  $\lambda_1 \dots \lambda_k = 1$  и  $\lambda_{k+1} \dots \lambda_n = 0$ .

$$\text{trace}(H) = \sum_i \lambda_i = k$$

2. По определению.

$$\text{trace}(H) = \text{trace}(X(X^T X)^{-1} X^T) = \text{trace}((X^T X)^{-1} X^T X) = \text{trace}(I_{k \times k}) = k.$$

## 2. Ковариация и ковариационная матрица

Пусть  $y_1, y_2 \in \mathbb{R}$  — скалярные случайные величины,  $a, b \in \mathbb{R}^n$  — вектора-столбцы чисел.

Дисперсия СВ:

$$\text{Var}(y_1) = E(y_1^2) - (E(y_1))^2.$$

Выборочная дисперсия столбца чисел:

$$\text{sVar}(a) = \frac{\sum_i^n (a_i - \bar{a})^2}{n - 1}$$

квадрат длины центрированного вектора, деленный на размерность подпространства, в котором лежит вектор.

Ковариация двух СВ:

$$\text{Cov}(y_1, y_2) = E y_1 y_2 - E y_1 E y_2 = E \left( (y_1 - E y_1)(y_2 - E y_2) \right).$$

Выборочная ковариация двух столбцов чисел:

$$\text{sCov}(a, b) = \frac{\sum_i (a_i - \bar{a})(b_i - \bar{b})}{n - 1}$$

скалярное произведение центрированных векторов, деленное на размерность пространства, в котором они лежат.

Корреляция двух СВ:

$$\text{Corr}(y_1, y_2) = \frac{\text{Cov}(y_1, y_2)}{\sqrt{\text{Var}(y_1)} \sqrt{\text{Var}(y_2)}}.$$

Выборочная корреляция двух столбцов чисел:

$$\text{sCorr}(a, b) = \frac{\text{sCov}(a, b)}{\sqrt{\text{sVar}(a)} \sqrt{\text{sVar}(b)}} = \cos(a - \bar{a}, b - \bar{b}).$$

**Упражнение:** Записать выборочную ковариационную матрицу для  $X$  в предположении, что переменные уже центрированы. Запишем матрицу  $X$  по строкам и по столбцам:

$$X = \begin{bmatrix} \vdots & & \vdots \\ c_1 & \dots & c_k \\ \vdots & & \vdots \end{bmatrix} = \begin{bmatrix} \dots & r_1^T & \dots \\ \vdots & & \vdots \\ \dots & r_n^T & \dots \end{bmatrix}.$$

Поймем, как выглядит  $\text{sVar}(X)$ :

$$\text{sVar}(X) = \begin{bmatrix} \text{sVar}(c_1) & \text{sCov}(c_1, c_2) & \dots & \text{sCov}(c_1, c_k) \\ \text{sCov}(c_2, c_1) & \text{sVar}(c_2) & \dots & \text{sCov}(c_2, c_k) \\ \vdots & & \ddots & \vdots \\ \text{sCov}(c_k, c_1) & \text{sCov}(c_k, c_2) & \dots & \text{sVar}(c_k, c_k) \end{bmatrix}$$

С учетом того что  $c_1 \dots c_k$  центрированы, ковариационную матрицу можно найти следующими способами:

$$\text{sVar}(X) = \frac{X^T X}{n - 1} = \frac{\sum_i^n r_i r_i^T}{n - 1}.$$

Чтобы удостовериться в правильности ответов, рассмотрим одну из ячеек ковариационной матрицы:

$$\text{sVar}(X)_{21} = \frac{c_2^T c_1}{n - 1} = \frac{\sum_i^n r_{i2} r_{i1}}{n - 1}.$$

### 3. Метод главных компонент

В методе главных компонент рассматривается способ понижения размерности при минимальных потерях в разбросе данных.

$$\min_{\mu, V: V^T V = I, \lambda_i} \sum_i^n \|r_i - \mu - V \lambda_i\|,$$

$r_i \in \mathbb{R}^k$  —  $i$ -ая строка матрицы  $X$ , записанная в столбец,  $\mu \in \mathbb{R}^k$  — вектор средних,  $V \in \mathbb{R}^{k \times p}$  — матрица, столбцы которой ортонормальны:  $V^T V = I$ ,  $\lambda_i \in \mathbb{R}^p$ ,  $k$  — исходная размерность,  $p$  — желаемая.

Предположим, что  $\mu$  и  $V$  найдены, выразим  $\lambda_i$ . Заметим, что для фиксированного  $i$  задача превращается в аналогичную задаче поиска коэффициентов линейной регрессии, поэтому можно сразу выписать ответ:

$$\lambda_i = (V^T V)^{-1} V^T (r_i - \mu) = V^T (r_i - \mu).$$

Далее будем считать, что переменные заранее центрированы, поэтому положим  $\mu = 0$ . Подставим выражение для  $\lambda_i$  в исходную задачу:

$$Q = \|r_i - V V^T r_i\| \rightarrow \min_{V: V^T V = I}.$$

Распишем:

$$Q = \sum_i^n (r_i - V V^T r_i)^T (r_i - V V^T r_i) = \sum_i^n r_i^T (I - V V^T) (I - V V^T) r_i.$$

Заметим, что  $V V^T$  — это матрица-шляпница, проецирующая  $r_i$  на линейную оболочку из  $v_1 \dots v_p$  столбцов матрицы  $V$ :

$$H = V(V^T V)^{-1} V^T = V V^T.$$

Тогда матрица  $I - V V^T$  является матрицей, проецирующей вектора  $r_i$  на ортогональное дополнение к пространству, натянутому на оболочку  $v_1 \dots v_p$ . Проекция на подпространство  $L$  вектора  $x \in L$  уже лежащего в этом подпространстве, равна  $x$ , поэтому  $(I - V V^T)(I - V V^T)x = (I - V V^T)x \quad \forall x$ . Получили:

$$Q = \sum_i^n r_i^T (I - V V^T) r_i.$$

Раскроем скобки:

$$Q = \sum_i^n r_i^T r_i - r_i^T V V^T r_i \rightarrow \min_{V: V^T V = I}.$$

Перейдем к эквивалентной задаче:

$$Q = r_i^T V V^T r_i \rightarrow \max_{V: V^T V = I}.$$

Так как  $Q \in \mathbb{R}$  — скаляр, то можно записать:

$$\begin{aligned} Q &= \text{trace}\left(\sum_i^n r_i^T V V^T r_i\right) = \text{trace}\left(V V^T \sum_i^n r_i r_i^T\right) \\ &= \text{trace}(V V^T (n-1) \text{sVar}(X)) = (n-1) \text{trace}(V \text{sVar}(X) V^T) = (n-1) \sum_j^p v_j^T \text{sVar}(X) v_j \end{aligned}$$

Перейдем к эквивалентной задаче:

$$Q' = \sum_j^p v_j^T S v_j \rightarrow \max,$$

где  $S = \text{sVar}(X)$ .  $Q'$  интерпретируется как выборочная дисперсия линейной комбинации столбцов матрицы  $X$ , взятых с весами вектора  $v_j$ .

**Упражнение.** Рассмотрим матрицу  $X \in \mathbb{R}^{n \times 2}$  и ее ковариационную матрицу:

$$X = \begin{bmatrix} \vdots & \vdots \\ c_1 & c_k \\ \vdots & \vdots \end{bmatrix},$$

$$\text{sVar}(X) = \begin{bmatrix} 5 & -1 \\ -1 & 16 \end{bmatrix}.$$

Будем искать выборочную дисперсию  $z = 3c_1 + 6c_2$ .

$$\text{Var}(3c_1 + 6c_2) = 9 \text{Var}(c_1) + 36 \text{Var}(c_2) + 18 \text{Cov}(c_1, c_2) = 9 \cdot 5 + 36 \cdot 16 + 18 \cdot (-1) = 603.$$

$$\begin{bmatrix} 3 & -6 \end{bmatrix} \begin{bmatrix} 5 & -1 \\ -1 & 16 \end{bmatrix} \cdot \begin{bmatrix} 3 \\ 6 \end{bmatrix} = 9 \cdot 5 + 36 \cdot 16 + 18 \cdot (-1) = 603.$$

Получилось, что выборочную дисперсию можно искать по формуле для дисперсии суммы, а можно через построение квадратичной формы.

Можно снова переписать оптимизируемый функционал:

$$V = \begin{bmatrix} \vdots & \vdots \\ v_1 & \dots & v_p \\ \vdots & \vdots \end{bmatrix},$$

$$\sum_j^p \text{sVar}(X v_j) \rightarrow \max_{V: V^T V = I}.$$

**Упражнение:** Найти главную компоненту  $X$ .

$$X = \begin{bmatrix} 3 & 5 \\ 2 & 1 \\ 1 & 3 \end{bmatrix}$$

Сначала нужно центрировать и нормировать данные:

$$\begin{bmatrix} 3 & 5 \\ 2 & 1 \\ 1 & 3 \end{bmatrix} \rightarrow \begin{bmatrix} 1 & 2 \\ 0 & -2 \\ -1 & 0 \end{bmatrix} \rightarrow \begin{bmatrix} 1 & 1 \\ 0 & -1 \\ -1 & 0 \end{bmatrix} = X'$$

С помощью метода главных компонент будем искать вектор  $v_1 \in \mathbb{R}^2$  — веса, с которыми нужно взять линейную комбинацию столбцов матрицы  $X$ , чтобы получить первую главную компоненту. Введем обозначение:

$$v_1 = \begin{bmatrix} \alpha \\ \beta \end{bmatrix},$$

тогда требования на ортонормированность базиса из векторов  $v$  в случае с одной главной компонентой — только нормированность) можно записать так:

$$\|v_1\| = 1 \rightarrow \alpha^2 + \beta^2 = 1.$$

Запишем оптимизируемый функционал:

$$Q = \text{sVar} \left( \alpha \begin{bmatrix} 1 \\ 0 \\ -1 \end{bmatrix} + \beta \begin{bmatrix} 1 \\ -1 \\ 0 \end{bmatrix} \right) \rightarrow \max_{\alpha, \beta: \alpha^2 + \beta^2 = 1}$$

Чтобы посчитать значение этого функционала, нужно посчитать ковариационную матрицу  $X'$ :

$$\text{sVar}(X') = \begin{bmatrix} 1 & \frac{1}{2} \\ \frac{1}{2} & 1 \end{bmatrix}.$$

Тогда

$$Q = \alpha^2 + \beta^2 + 2\alpha\beta\frac{1}{2} = 1 + \alpha\beta.$$

Решением задачи:

$$\begin{cases} \alpha\beta \rightarrow \max \\ \alpha^2 + \beta^2 = 1 \end{cases}$$

являются точки  $\alpha = \beta = \frac{1}{\sqrt{2}}$  и  $\alpha = \beta = -\frac{1}{\sqrt{2}}$ . Знак здесь задает только ориентацию вектора, поэтому можно рассматривать любую из точек.

Теперь можно записать главную компоненту:

$$pc_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 0 \\ -1 \end{bmatrix} + \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \\ 0 \end{bmatrix} = \begin{bmatrix} \frac{2}{\sqrt{2}} \\ \frac{-1}{\sqrt{2}} \\ \frac{-1}{\sqrt{2}} \end{bmatrix}$$

Поиск нескольких главных компонент можно осуществлять, последовательно решая задачи:

$$\begin{cases} \text{sVar}(Xv_1) \rightarrow \max \\ \|v_1\| = 1 \end{cases}$$

$$\begin{cases} \text{sVar}(Xv_2) \rightarrow \max \\ \|v_2\| = 1 \\ v_2^T v_1 = 0 \end{cases}$$

$$\begin{cases} \text{sVar}(Xv_3) \rightarrow \max \\ \|v_3\| = 1 \\ v_3^T v_1 = 0 \\ v_3^T v_2 = 0 \end{cases}$$

**Упражнение:** Если  $V^T V = I$ , то  $V$  сохраняет длины.

$$\|Va\| = a^T V^T V a = \|a\|.$$

**Упражнение:** Если  $\|a\| = 1$ , то

$$\max_a a^T \begin{bmatrix} 1 & 0 & 0 \\ 0 & 3 & 0 \\ 0 & 0 & 1 \end{bmatrix} a = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}.$$

## 4. Связь с SVD-разложением

Рассмотрим поиск первой главной компоненты:

$$\max_{v_1: \|v_1\|=1} \text{sVar}(Xv_1) = \max_{v_1: \|v_1\|=1} v_1^T \frac{X^T X}{n-1} v_1 = \max_{v_1: \|v_1\|=1} v_1^T X^T X v_1$$

SVD-разложение:

$$\begin{aligned} X &= U \Sigma V^T \\ X^T X &= V \Sigma^T \Sigma V^T \end{aligned}$$

Подставим в оптимизируемый функционал:

$$\max_{v_1: \|v_1\|=1} v_1^T V \Sigma^T \Sigma V v_1.$$

Так как  $V^T V = I$ , то  $V$  сохраняет длины, поэтому  $\|V v_1\| = \|v_1^T V\| = 1 \iff \|v_1\| = 1$ , а значит можно переписать задачу:

$$\max_{v'_1: \|v'_1\|=1} v'^T_1 \Sigma^T \Sigma V v'_1 = \max_{v'_1: \|v'_1\|=1} v'_1 \begin{bmatrix} \lambda_1 & \dots & 0 \\ & \ddots & \\ 0 & \dots & \lambda_n \end{bmatrix} v'_1 = \begin{bmatrix} 1 \\ 0 \\ \vdots \\ 0 \end{bmatrix}$$

здесь  $\lambda_1 \dots \lambda_n$  — собственные числа матрицы  $\Sigma^T \Sigma$ , отсортированные по убыванию.

Сейчас мы нашли  $v'_1$ , но нужно найти  $v_1$ .

$$V^T v_1 = \begin{bmatrix} 1 \\ 0 \\ \vdots \\ 0 \end{bmatrix}$$

$$V V^T v_1 = v_1 = V \begin{bmatrix} 1 \\ 0 \\ \vdots \\ 0 \end{bmatrix}$$

Получилось, что искомый столбец  $v_1$  для PCA — это столбец матрицы  $V$  из SVD разложения  $X$ , соответствующий первому по величине значению в матрице  $\Sigma$  ( $\Sigma_{ii} = \sqrt{\lambda_i}$ ).

$$pc_1 = X v_1 = (U \Sigma V^T) v_1 = U \Sigma \begin{bmatrix} 1 \\ 0 \\ \vdots \\ 0 \end{bmatrix} = \sqrt{\lambda_1} u_1.$$

Это верно для всех рассматриваемых главных компонент:

$$pc_j = \sqrt{\lambda_j} u_j.$$