

Конспектировал: Ефим Лубошников.

1. Свойства математического ожидания

Вспомним, какими свойствами обладает математическое ожидание случайной величины и случайного вектора. Обозначим: y_1, y_2 — случайные величины, y, z — случайные вектора, a — скалярная константа, A, B — матрицы констант.

Случайная величина	Случайный вектор
$E(ay_1) = a E(y_1)$	$E(AyB) = A E(y) B$
$\text{Var}(y_1) = E(y_1^2) - E(y_1)^2$	$\text{Var}(y) = E(yy^T) - E(y) E(y^T)$
$\text{Var}(ay_1) = a^2 \text{Var}(y_1)$	$\text{Var}(Ay) = A(E(yy^T) - E(y) E(y^T))A^T$
$\text{Var}(a + y_1) = \text{Var}(y_1)$	$\text{Var}(a + y) = \text{Var}(y)$
$\text{Cov}(y_1, y_2) = E(y_1 y_2) - E(y_1) E(y_2)$	$\text{Cov}(y, z) = E(yz^T) - E(y) E(z^T)$
	$\text{Cov}(Ay, Bz) = A \text{Cov}(y, z) B^T$
	$\text{Cov}(y, z) = \text{Cov}(z, y)^T$
	Если $y, z \in \mathbb{R}^n$, то справедливо:
	$\text{Cov}(y + z, w) = \text{Cov}(y, w) + \text{Cov}(z, w)$
	$\text{Var}(y + z) = \text{Var}(y) + \text{Var}(z) + \text{Cov}(y, z) + \text{Cov}(z, y)$

Так выглядит дисперсия случайного вектора $y \in \mathbb{R}^n$:

$$\text{Var}(y) = \begin{bmatrix} \text{Var}(y_1) & \text{Cov}(y_1, y_2) & \dots & \text{Cov}(y_1, y_n) \\ \text{Cov}(y_2, y_1) & \text{Var}(y_2) & \dots & \text{Cov}(y_2, y_n) \\ \vdots & \vdots & \dots & \vdots \\ \text{Cov}(y_n, y_1) & \text{Cov}(y_n, y_2) & \dots & \text{Var}(y_n) \end{bmatrix}$$

2. Предпосылки для теоремы Гаусса-Маркова

Рассмотрим задачу регрессии $y = X\beta + u$ в случае двух регрессоров: $y_i = \beta_1 + \beta_2 x_i + \beta_3 z_i + u_i$
Предпосылки:

1. Предполагаем β — неизвестная константа.
2. X должен иметь полный ранг, чтобы оценки МНК существовали. X может быть:
 - а) известная константа, $y_t = \beta_1 + \beta_2 t + u_t$
 - б) наблюдение - случайная величина, временной ряд.
3. Гомоскедастичность: $\text{Var}(u_i|X) = \sigma^2 I$
4. Отсутствие автокорреляции: $\text{Cov}(u_i, u_j|x) = 0, i \neq j$
5. $E(u|X) = 0$

Обозначим:

- \hat{y} — предсказанный y на тренировочной выборке.
- \hat{y}_{test} — предсказанный y на тестовой выборке.

2.1. Упражнение "Мега-матрица"

Задание: Заполнить матрицу Var, Cov для соответствующих элементов матрицы:

	y	\hat{y}	u	\hat{u}	$\hat{\beta}$
y					
\hat{y}					
u					
\hat{u}					
$\hat{\beta}$					
y_{test}					
\hat{y}_{test}					
\hat{u}_{test}					

Решение:

Будем пользоваться результатами, полученными ранее:

$$\hat{\beta} = (X^T X)^{-1} X^T y$$

$$\hat{y} = X \hat{\beta}$$

$$\hat{u} = y - \hat{y}$$

$$y_{test} = X_{test} \beta + u_{test}$$

$$\hat{y}_{test} = X_{test} \hat{\beta}$$

Предварительно найдём математические ожидания:

$$E(y|X) = E(X\beta + u|X) = X\beta + E(u|X) = X\beta$$

$$E(\beta|X) = E((X^T X)^{-1} X^T y|X) = E((X^T X)^{-1} X^T X \beta|X) = (X^T X)^{-1} X^T X \beta = \beta$$

Получим элементы мега-матрицы:

$$\text{Var}(y|X) = \text{Var}(X\beta + u|X) = \text{Var}(u|X) = \sigma^2 I$$

$$\begin{aligned} \text{Var}(\beta|X) &= \text{Var}((X^T X)^{-1} X^T y|X) = (X^T X)^{-1} X^T \text{Var}(y|X) ((X^T X)^{-1} X^T)^T = \\ &= (X^T X)^{-1} X^T \sigma^2 X (X^T X)^{-1} = \sigma^2 (X^T X)^{-1} X^T X (X^T X)^{-1} = \sigma^2 (X^T X)^{-1} \end{aligned}$$

$$\begin{aligned} \text{Cov}(\hat{\beta}, \hat{u}|X) &= \text{Cov}((X^T X)^{-1} X^T y, y - \hat{y}|X) = \text{Cov}((X^T X)^{-1} X^T y, y|X) - \text{Cov}((X^T X)^{-1} X^T y, \hat{y}|X) = \\ &= (X^T X)^{-1} X^T \text{Var}(y|X) - \text{Cov}(\beta, X\beta|X) = \sigma^2 (X^T X)^{-1} X^T - \sigma^2 (X^T X)^{-1} X^T = 0 \end{aligned}$$

На контрольной работе - вывести 2 элемента мега-матрицы.

2.2. Математическое ожидание RSS

RSS можно представить как:

$$RSS = \sum_{i=1}^n \hat{u}_i^2 = \hat{u}^T \hat{u} = ((I - H)y)^T ((I - H)y) = y^T (I - H)^T (I - H)y = y^T (I - H)y$$

Далее, найдем математическое ожидание RSS при фиксированном X :

$$\begin{aligned} E(RSS|X) &= E(y^T (I - H)y|X) = E(tr(y^T (I - H)y|X)) = E(tr(I - H)yy^T|X)) = tr((I - H) E(yy^T)) = \\ &= trace(I - H)(Var(y|X) + E(y|X) E(y^T|X)) = tr(I - H)(\sigma^2 I + X\beta\beta^T X^T) = tr[(I - H)(\sigma^2 I + X\beta\beta^T X^T)] = \\ &= trace(I - H)\sigma^2 + tr((I - H)(X\beta\beta^T X^T)) = tr(I - H)\sigma^2 = (n - k)\sigma^2 = (n - k)\sigma^2 \end{aligned}$$

Слагаемое $(I - H)X = 0$, так как $(I - H)$ — проекция на ортогональное дополнение к X . Можем сделать вывод, что оценка $\hat{\sigma}^2 = \frac{RSS}{n-k}$ — несмещённая.

3. Теорема Гаусса-Маркова

Теорема 3.1. Если:

- Выполняются предпосылки про β , u , X ;
- Помимо МНК-оценки $\hat{\beta} = (X^T X)^{-1} X^T y$ существует альтернативная несмещённая оценка $\hat{\beta}_{alt} = A_{alt}^T y$

то можно утверждать, что:

- $Var(\hat{\beta}_{alt_j}|X) \geq Var(\hat{\beta}_j|X)$
- Матрица $\Delta = Var(\hat{\beta}_{alt}|X) - Var(\hat{\beta}|X)$ является неотрицательно положительно определённой.

Замечание.

Первая формулировка является частным и упрощённым вариантом второй формулировки.

Доказательство. $\hat{\beta} = ((X^T X)^{-1} X^T)^T y = A^T y$

$\hat{\beta}_1$ — первая строка из A^T , умноженная на y . Также $\hat{\beta}_1 = \langle \text{первый столбец в } A, y \rangle$. Матрица A задаёт веса, с которыми надо брать y , чтобы получить $\hat{\beta}$. Рассмотрим, каким образом собрана матрица A :

$$A = X \cdot (X^T X)^{-1}$$

Для этого обозначим столбцы матрицы A векторами c_1, c_1, \dots, c_k :

$$A = \begin{pmatrix} \vdots & \vdots & \dots & \vdots \\ c_1 & c_2 & \dots & c_k \\ \vdots & \vdots & \vdots & \vdots \end{pmatrix} \cdot \begin{pmatrix} * & \dots \\ * & \dots \\ \vdots & \dots \\ * & \dots \end{pmatrix}$$

Первый столбец матрицы A формируется, как линейная комбинация столбцов c_i :

$$a_1 = * \cdot c_1 + * \cdot c_2 + \dots + * \cdot c_k$$

Беса, с которыми надо брать y , чтобы получить $\hat{\beta}$, являются линейной комбинацией столбцов матрицы X .

$$\text{Дисперсия } \text{Var}(\hat{\beta}_1|X) = \text{Var}(a_1^T y|X) = a_1^T \sigma^2 I a_1 = \sigma^2 a_1^T a_1 = \sigma^2 \cdot \|a_1\|^2$$

$$\text{Var}(\hat{\beta}_1^{alt}|X) = \sigma^2 \|a_1^{alt}\|^2 \geq \text{Var}(\hat{\beta}_1|X)$$

Краткая схема доказательства:

1. $a_1 \in \text{Lin}(\text{столбцы } X)$
Это следует из $A = X(X^T X)^{-1}$
2. $a_1^{alt} - a_1 \perp \text{Lin}(\text{столбцы } X)$
Это следует из $(a_1^{alt})^T X \beta = \beta_1 = a_1^T X \beta$

Рассмотрим доказательство для общего случая:

Введём матрицу $\Delta = \text{Var}(\hat{\beta}^{alt}|X) - \text{Var}(\hat{\beta}|X)$. Нам нужно доказать, что матрица Δ неотрицательно определённая. Для этого для любого вектора w нужно, чтобы $w^T \Delta w \geq 0$. Или, эквивалентно:

$$\text{Var}(w^T \hat{\beta}^{alt}|X) \geq \text{Var}(w^T \hat{\beta}|X)$$

$$\text{Var}(a_{alt}^T Y|X) \geq \text{Var}(a^T y|X)$$

Далее доказательство, как и для частного случая:

1. $a \in \text{Lin}(\text{столбцы } X)$
2. $a^T - a \perp \text{Lin}(\text{столбцы } X)$

□

4. Теоремы без доказательства

Если верны предпосылки о β , X , u , и известно, что $u \sim N(0; \sigma^2 I)$, то:

1. $\hat{\beta}_j|X \sim N(\beta_j, \text{Var}(\hat{\beta}_j|X))$
2. $\frac{\hat{\beta}_j - \beta_j}{\sqrt{\text{Var}(\hat{\beta}_j|X)}} = \frac{\hat{\beta}_j - \beta_j}{se(\hat{\beta}_j)} \sim t_{n-k}$
3. Если существуют две вложенные модели: «short» — частный случай «long», то:

$$\frac{(RSS_s - RSS_l)/(k_l - k_s)}{RSS_l/(n - k_l)} \sim F_{k_l - k_s, n - k_l}$$

4.1. Задача

Дано: 200 наблюдений.

Модель А: $\hat{y}_i = 2.7 - 3.2x_i$, $R^2 = 0.6$
(1.1) (0.6)

Модель В: $\hat{y}_i = 3.2 - 2.8x_i + 4.2z_i + 0.1x_i^2$, $R^2 = 0.7$
(1.2) (0.7) (1.1) (0.5)

В скобках ниже указаны стандартные ошибки, standard errors, $se(\hat{\beta})$

Задание:

1. Проверьте гипотезу при уровне значимости $\alpha = 5\%$

H_0 : верна модель А.

H_A : модель А неверна, но верна модель В.

2. Постройте 95% доверительный интервал для β_x .

Решение

Из теоремы 2:

$$\frac{\hat{\beta}_x - \beta_x}{se(\hat{\beta}_x)} \sim t_{200-2}$$

Наблюдений много, поэтому t -распределение с 198 степенями свободы очень похоже на нормальное.

$$t_{198} = N(0; 1)$$

$$-t_{cr} \leq \frac{\hat{\beta}_x - \beta_x}{se(\hat{\beta}_x)} \leq t_{cr}$$

Дробь с вероятностью 95% лежит от -1.96 до 1.96 .

$$\beta_x \in [\hat{\beta}_x - t_{cr} se(\hat{\beta}_x); \hat{\beta}_x + t_{cr} se(\hat{\beta}_x)]$$

$$\beta_x \in [-3.2 - 1.96 \cdot 0.6; -3.2 + 1.96 \cdot 0.6] \approx [-4.4; -2.0]$$

Замечаем, что $\beta_x = 0$ не попадает в $[-4.4; -2.0]$.

$$H_0 : \beta_x = 0$$

$$H_A : \beta \neq 0, \alpha = 5\%$$

H_0 отвергается, $\hat{\beta}_x$ значительно отличается от нуля.

$$R^2 = 1 - \frac{RSS}{TSS}$$

Воспользуемся третьей теоремой:

$$\frac{\frac{RSS_s - RSS_l}{k_l - k_s}}{\frac{RSS_l}{n - k_l}} \sim F_{k_l - k_s, n - k_l}$$

$$\frac{\frac{RSS_s - RSS_l}{4 - 2}}{\frac{RSS_l}{200 - 4}} = \frac{\frac{RSS_s - RSS_l}{TSS} / 2}{\frac{RSS_l}{TSS} / 196} = \frac{(0.4 - 0.3) \cdot 196}{2 \cdot 0.3} \approx 3.04$$

$$F_{cr} = 3.04$$

Сравним F_{cr} с $F_{2,196}$, видим, что гипотеза H_0 отвергается, поэтому выбираем модель В для оценки.