

Конспектировали: Ирина Долгалева и Дарья Краснова

## 1. Свойства многомерного нормального распределения

Случайный вектор  $u$  имеет многомерное нормальное стандартное распределение

$$u = \begin{pmatrix} u_1 \\ u_2 \\ \vdots \\ \vdots \\ \vdots \\ \vdots \\ u_n \end{pmatrix} \sim \mathcal{N}(0, I)$$

каждое  $u_i \sim \mathcal{N}(0, 1)$  и независимы. Такой вектор удовлетворяет ряду аксиом.

**Аксиомы:** 1. В любом ортонормальном базисе закон распределения  $u$  одинаковый

2.  $u_i$  — независимы

3.  $Var(u_i) = 1$

⇓ Из этих аксиом следует два важных текстовых свойства нормального распределения.

**Свойства:** 1. Квадрат длины проекции  $u$  на  $V$  ( $\dim(V) = d$ ) имеет  $\sim \chi_d^2$  распределение

2. Квадраты длин проекции на  $V$  и  $W$  независимы, если  $V \perp W$

## 2. t — распределение

**Классическое определение.**

Случайная величина  $T$

$$T = \frac{z}{\sqrt{\frac{\gamma_k}{k}}}$$

где  $z \sim \mathcal{N}(0, 1)$ ,  $\gamma_k \sim \chi_k^2$ , имеет  $t$ -распределение с  $k$  степенями свободы, где  $z, \gamma_k$  — независимы.

**Геометрическое определение.**


Рассмотрим  $V$  — одномерное линейное подпространство, задаваемое вектором единичной длины  $v$  и ортогональное ему подпространство  $W$  размерности  $k$ :

$$V = \text{Lin}(v), \dim(V) = 1 \\ \|v\|=1$$

$$W = \text{Col}(X), \dim(W) = k$$

$$V \perp W$$

Пусть  $u$  вектор пространства  $\mathbb{R}^n$ ,  $\hat{u}_V = z \cdot v$  — проекция  $u$  на  $V$ ,  $\hat{u}_W$  — проекция  $u$  на  $W$ ,  $\hat{u}_{W+V}$  — проекция  $u$  на  $W \oplus V$ .




Тогда, случайная величина  $T$

$$T = \frac{z}{\sqrt{\frac{\|\hat{u}_W\|^2}{\dim(W)}}} = \operatorname{tg} \alpha \cdot \sqrt{\dim(W)} \sim t(k)$$

имеет  $t$ -распределение с  $k$  степенями свободы, где  $\alpha$  — угол между  $\hat{u}_W$  и  $\hat{u}_{V+W}$ .

Рассмотрим подпространство  $V + W$ :



$v$  — нормаль (единичной длины) к  $W \Rightarrow v \perp W$   
 $\hat{u}_W$  — проекция  $u$  на  $W$ ;  $\dim(W) = k \Rightarrow \|\hat{u}_W\|^2 \sim \chi_k^2$   
 Получаем эквивалентные определения.

### 3. $\mathcal{F}$ – распределение

Классическое определение.

Случайная величина  $F$

$$F = \frac{\frac{\gamma_a}{a}}{\frac{\gamma_b}{b}} \sim \mathcal{F}_{a,b},$$

имеет  $\mathcal{F}$  – распределение с  $(a, b)$  степенями свободы, где  $\gamma_a \sim \chi_a^2$ ,  $\gamma_b \sim \chi_b^2$  и  $\gamma_a, \gamma_b$  независимы.

Геометрическое определение.


Рассмотрим  $V$  – линейное подпространство размерности  $a$  и ортогональное ему подпространство  $W$  размерности  $b$ :

$$\dim(V) = a, \quad \dim(W) = b$$

$$V \perp W$$

$$\dim(V) + \dim(W) \leq n \text{ все в } \mathbb{R}^n$$

Пусть  $u$  – вектор пространства  $\mathbb{R}^n$ ,  $u \sim \mathcal{N}(0, I)$ .  $\hat{u}_V$  – проекция  $u$  на  $V$ ,  $\hat{u}_W$  – проекция  $u$  на  $W$ ,  $\hat{u}_{W+V}$  – проекция  $u$  на  $W \oplus V$ .



Тогда, случайная величина  $F$

$$F = \frac{\frac{\|\hat{u}_V\|^2}{\dim(V)}}{\frac{\|\hat{u}_W\|^2}{\dim(W)}} = \tan^2 \alpha \cdot \frac{\dim(W)}{\dim(V)} \sim \mathcal{F}(\dim(V), \dim(W)) = \mathcal{F}(a, b)$$

имеет  $\mathcal{F}$  – распределение с  $(\dim(V), \dim(W))$  степенями свободы, где  $\alpha$  – угол между  $\hat{u}_W$  и  $\hat{u}_{W+V}$ .

$\hat{u}_V$  - проекция  $u$  на  $V$ ;  $\dim(V) = a \Rightarrow \|\hat{u}_V\|^2 \sim \chi_a^2$   
 $\hat{u}_W$  - проекция  $u$  на  $W$ ;  $\dim(W) = b \Rightarrow \|\hat{u}_W\|^2 \sim \chi_b^2$   
 Получаем эквивалентные определения.

Заметим, что  $t$ -статистика — это частный случай  $\mathcal{F}$ -статистики:

$$T^2 = F, \dim(V) = a = 1$$

## 4. Связь $\mathcal{F}$ распределения и эконометрических моделей

**Теорема.** Рассмотрим задачу регрессии и предположим:

1. Предполагаем  $y = X\beta + u$ .

2. Оцениваем:

а) длинную модель  $\hat{y}^L = X\hat{\beta}^L$  (верная модель)

$$\min_{\hat{\beta}^L} \sum_{i=1}^n (y_i - \hat{y}_i^L)^2$$

б) короткую модель  $\hat{y}^S = X\hat{\beta}^S$  (считаем, что последние  $d$  коэффициента - нулевые)

$$\min_{\hat{\beta}^S} \sum_{i=1}^n (y_i - \hat{y}_i^S)^2$$

$$\hat{\beta}_k = \hat{\beta}_{k-1} = \dots = \hat{\beta}_{k-d+1} = 0$$

3. Стандартные предпосылки

а)  $X$  — полного ранга, неслучайная

б)  $u \sim \mathcal{N}(0, \sigma^2 I) \equiv u_i \sim \mathcal{N}(0, \sigma^2), u_i$  — независимы

4. Проверяем гипотезу

$H_0$ : Верна короткая модель

$H_A$ : Короткая модель не верна

То,

$$1. \frac{RSS_L}{\sigma^2} \sim \chi_{n-k_L}^2$$

Если верна  $H_0$ :


$$2. \frac{RSS_S - RSS_L}{\sigma^2} \sim \chi_{k_L - k_S}^2$$

3.  $RSS_L$  и  $(RSS_S - RSS_L)$  — независимы

$$4. \frac{\frac{RSS_S - RSS_L}{k_L - k_S}}{\frac{RSS_L}{n - k_L}} \sim \mathcal{F}_{k_L - k_S, n - k_L}$$


Доказательство.

1.  $\hat{u} = (I - H)y = (I - H)(X\beta + u) = [(I - H)X\beta = 0] = (I - H)u \Rightarrow$   
 $\hat{u}_L$  — проекция  $u$  на  $\text{Col}^\perp(X_L)$ ,  $\dim(\text{Col}^\perp(X_L)) = n - k_L \Rightarrow$   
 $RSS_L = \|\hat{u}_L\|^2$  — квадрат длины проекции  $u$  на  $(n - k_L)$ -мерное подпространство



2. Теперь дополнительно предположим, что еще верна короткая модель (опускаем регрессоры, отвечающие за нулевые компоненты)

$$X = \begin{bmatrix} 1 & x_1 & z_1 & q_1 & w_1 \\ 1 & x_2 & z_2 & q_2 & w_2 \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ 1 & x_n & z_n & q_n & w_n \end{bmatrix} \Rightarrow X_S = \begin{bmatrix} 1 & x_1 & z_1 \\ 1 & x_2 & z_2 \\ \vdots & \vdots & \vdots \\ 1 & x_n & z_n \end{bmatrix}$$



$$RSS_S - RSS_L = \|\hat{u}_S\|^2 - \|\hat{u}_L\|^2 = \|\hat{y}_S - \hat{y}_L\|^2 = \sum_{i=1}^n (\hat{y}_i^S - \hat{y}_i^L)^2$$

$(\hat{y}_i^S - \hat{y}_i^L)$  – проекция  $y$  на  $\text{Col } X_L \cap \text{Col}^\perp X_S$  (ортогональное дополнение  $X_S$  в подпространстве  $X_L$ )

$$\dim(\text{Col } X_L \cap \text{Col}^\perp X_S) = \dim(\text{Col } X_L) - \dim(\text{Col}^\perp X_S) = k_L - k_S \Rightarrow$$

$$\frac{RSS_S - RSS_L}{\sigma^2} \sim \chi_{k_L - k_S}^2$$

3.  $RSS_L$  и  $(RSS_S - RSS_L)$  – независимы, поскольку они ортогональны

$$4. \frac{\frac{RSS_S - RSS_L}{\sigma^2 (k_L - k_S)}}{\frac{RSS_L}{\sigma^2 (n - k_L)}} = \frac{\frac{RSS_S - RSS_L}{k_L - k_S}}{\frac{RSS_L}{n - k_L}} \sim \mathcal{F}_{k_L - k_S, n - k_L}$$

□

## 5. Матрица-мать всех матриц

Пусть дана матрица  $X$ :

$$X = \begin{bmatrix} \vdots & \vdots & \vdots & \vdots \\ x_1 & x_2 & \vdots & x_k \\ \vdots & \vdots & \vdots & \vdots \end{bmatrix};$$

Она состоит из центрированных векторов-столбцов  $x_j$  таких, что  $\bar{x}_j = 0$  и  $\sum_{i=1}^n x_{ij} = 0$ . Тогда матрицы  $W$  и  $M$  определяются как:

$$W = X^T X; M = W^{-1}$$

Что же находится в матрице  $M$ ?

Построим регрессию  $x_1$  на  $x_1, x_2, \dots, x_k$ . Тогда:

$$\hat{x}_1 = \hat{\alpha}_2 x_2 + \hat{\alpha}_3 x_3 + \dots + \hat{\alpha}_k x_k$$


$$\tilde{x}_1 = x_1 - (\hat{\alpha}_2 x_2 + \hat{\alpha}_3 x_3 + \dots + \hat{\alpha}_k x_k)$$

**Упражнение:** доказать, что:

$$\begin{cases} \langle \tilde{x}_1, x_2 \rangle = 0 \\ \langle \tilde{x}_1, x_3 \rangle = 0 \\ \vdots \\ \langle \tilde{x}_1, x_k \rangle = 0 \end{cases}$$

*Доказательство.*

Доказательство следует напрямую из картинки:



Вектор  $\tilde{x}_1$  ортогонален линейной оболочке  $\text{lin}(x_2, \dots, x_k)$ , а значит ортогонален всем векторам, лежащим в ней. Получаем требуемое. □

Пользуясь этим знанием, посчитаем, чему равно  $\langle \tilde{x}_1, x_1 \rangle$ :

$$\langle \tilde{x}_1, x_1 \rangle = \langle \tilde{x}_1, \tilde{x}_1 + (\hat{\alpha}_2 x_2 + \hat{\alpha}_3 x_3 + \dots + \hat{\alpha}_k x_k) \rangle = \langle \tilde{x}_1, \tilde{x}_1 \rangle = \|\tilde{x}_1\|^2$$

Введем неожиданную нормировку:

$$\check{x}_1 = \frac{\tilde{x}_1}{\|\tilde{x}_1\|^2},$$

где  $\tilde{x}_1$  — остаток от регрессии  $x_1$  на  $x_2, x_3, \dots, x_k$ ,  $\|\tilde{x}_1\|^2$  — квадрат длины вектора остатков  $\tilde{x}_1$ .

Почему была выбрана именно такая нормировка? Потому что хотели подобрать такую нормировку, двукратное применение которой к вектору  $v$  давало бы сам вектор  $v$ :

$$v \xrightarrow{g} \frac{v}{\|v\|^2}; g(g(v)) = v$$

Например,

$$\begin{pmatrix} 0 \\ 5 \end{pmatrix} \xrightarrow{g} \begin{pmatrix} 0 \\ \frac{1}{5} \end{pmatrix} \xrightarrow{g} \begin{pmatrix} 0 \\ 5 \end{pmatrix}$$

Покажем, что нормировка действительно удовлетворяет приведенному выше свойству для любого вектора  $v$ :

$$g(g(v)) = \frac{\frac{v}{\|v\|^2}}{\left\| \frac{v}{\|v\|^2} \right\|^2} = \frac{\frac{v}{\|v\|^2}}{\frac{1}{\|v\|^2} \cdot \|v\|^2} = v$$

Аналогично, запишем формулу неожиданной нормировки для вектора остатков  $\tilde{x}_2$ :

$$\check{x}_2 = \frac{\tilde{x}_2}{\|\tilde{x}_2\|^2},$$

где  $\tilde{x}_2$  — остаток от регрессии  $x_2$  на  $x_1, x_3, \dots, x_k$ ,  $\|\tilde{x}_2\|^2$  — квадрат длины вектора остатков  $\tilde{x}_2$ . Из векторов  $\tilde{x}_1, \tilde{x}_2, \dots, \tilde{x}_k$  можно составить матрицу  $\tilde{X}$ :

$$\tilde{X} = \begin{bmatrix} \vdots & \vdots & \vdots & \vdots \\ \tilde{x}_1 & \tilde{x}_2 & \dots & \tilde{x}_k \\ \vdots & \vdots & \vdots & \vdots \end{bmatrix}$$

Таким образом, матрица  $\tilde{X}$  — это матрица странным образом отнормированных остатков в  $k$  регрессиях.

Как выглядит ковариационная матрица этих остатков? Для этого поймем, чему равна матрица  $\tilde{X}^T \tilde{X}$ .

Пусть  $c_{11}$  —  $(1, 1)$  элемент матрицы  $\tilde{X}^T \tilde{X}$ , а  $c_{12}$  —  $(1, 2)$  элемент. Тогда:

$$c_{11} = \langle \tilde{x}_1, \tilde{x}_1 \rangle = \|\tilde{x}_1\|^2 = \left\| \frac{\tilde{x}_1}{\|\tilde{x}_1\|^2} \right\|^2 = \frac{1}{\|\tilde{x}_1\|^2} = \frac{1}{RSS_1}$$

$$c_{12} = \langle \tilde{x}_1, \tilde{x}_2 \rangle = \frac{1}{\|\tilde{x}_1\|^2} \cdot \frac{1}{\|\tilde{x}_2\|^2} \langle \tilde{x}_1, \tilde{x}_2 \rangle$$

Для того, чтобы найти  $\langle \tilde{x}_1, \tilde{x}_2 \rangle$ , выпишем, чему они равны в явном виде:

$$\tilde{x}_1 = x_1 - (\hat{\alpha}_2 x_2 + \hat{\alpha}_3 x_3 + \dots + \hat{\alpha}_k x_k)$$

$$\tilde{x}_2 = x_2 - (\hat{\beta}_1 x_1 + \hat{\beta}_3 x_3 + \dots + \hat{\beta}_k x_k)$$

Тогда  $\langle \tilde{x}_1, \tilde{x}_2 \rangle$  можно представить двумя способами (заменяя  $\tilde{x}_1$  или  $\tilde{x}_2$ ):

1.  $\langle \tilde{x}_1, \tilde{x}_2 \rangle = \langle x_1 - (\hat{\alpha}_2 x_2 + \hat{\alpha}_3 x_3 + \dots + \hat{\alpha}_k x_k), \tilde{x}_2 \rangle = -\hat{\alpha}_2 \langle \tilde{x}_2 \rangle = -\hat{\alpha}_2 \|\tilde{x}_2\|^2$
2.  $\langle \tilde{x}_1, \tilde{x}_2 \rangle = \langle \tilde{x}_1, x_2 - (\hat{\beta}_1 x_1 + \hat{\beta}_3 x_3 + \dots + \hat{\beta}_k x_k) \rangle = -\hat{\beta}_1 \langle \tilde{x}_1, \tilde{x}_1 \rangle = -\hat{\beta}_1 \|\tilde{x}_1\|^2$

При этом мы пользовались тем, что:

$$\tilde{x}_1 \perp x_2, x_3, \dots, x_k$$

$$\tilde{x}_2 \perp x_1, x_3, \dots, x_k$$

Вернемся к нахождению  $c_{12}$ :

$$c_{12} = \langle \tilde{x}_1, \tilde{x}_2 \rangle = \frac{1}{\|\tilde{x}_1\|^2} \cdot \frac{1}{\|\tilde{x}_2\|^2} \langle \tilde{x}_1, \tilde{x}_2 \rangle = \frac{-\hat{\beta}_1}{\|\tilde{x}_2\|^2} = \frac{-\hat{\alpha}_2}{\|\tilde{x}_1\|^2}$$

Таким образом, бесплатно получили следующее:

$$\frac{(\text{коэффициент при } x_2 \text{ в регрессии } x_1 \text{ на ост.})}{RSS_1} = \frac{(\text{коэффициент при } x_1 \text{ в регрессии } x_2 \text{ на ост.})}{RSS_2}$$

**Упражнение:** доказать, что  $\tilde{X}^T \tilde{X} = I$ .



*Доказательство.*

Для этого найдем  $(1, 1)$  и  $(1, 2)$  элементы матрицы  $\check{X}^T X = I$ :

$$b_{11} = \langle \check{x}_1, x_1 \rangle = \left\langle \frac{\check{x}_1}{\|\check{x}_1\|^2}, x_1 \right\rangle = \langle \check{x}_1, x_1 \rangle \cdot \frac{1}{\|\check{x}_1\|^2} = \langle \check{x}_1, \check{x}_1 \rangle \cdot \frac{1}{\|\check{x}_1\|^2} = 1$$

$$b_{12} = \langle \check{x}_1, x_2 \rangle = \langle \check{x}_1, x_2 \rangle \cdot \frac{1}{\|\check{x}_1\|^2} = 0$$

□

**Упражнение:** пусть

$$W = X^T X$$

$$M = \check{X}^T \check{X}$$

Доказать, что  $M \cdot W = I$  (то есть  $M = W^{-1}$ ).

*Доказательство.*

Из предыдущей части лекции известно, чему равны матрицы  $M$  и  $W$ :

$$M = \begin{bmatrix} \frac{1}{\langle \check{x}_1, \check{x}_1 \rangle} & \frac{-\hat{\alpha}_2}{\langle \check{x}_1, \check{x}_1 \rangle} & \frac{-\hat{\alpha}_3}{\langle \check{x}_1, \check{x}_1 \rangle} & \cdots \\ -\hat{\beta}_1 & 1 & -\hat{\beta}_3 & \vdots \\ \frac{\langle \check{x}_2, \check{x}_2 \rangle}{\langle \check{x}_2, \check{x}_2 \rangle} & \frac{\langle \check{x}_2, \check{x}_2 \rangle}{\langle \check{x}_2, \check{x}_2 \rangle} & \frac{\langle \check{x}_2, \check{x}_2 \rangle}{\langle \check{x}_2, \check{x}_2 \rangle} & \vdots \\ -\hat{\gamma}_1 & -\hat{\gamma}_2 & \ddots & \vdots \\ \frac{\langle \check{x}_3, \check{x}_3 \rangle}{\langle \check{x}_3, \check{x}_3 \rangle} & \frac{\langle \check{x}_3, \check{x}_3 \rangle}{\langle \check{x}_3, \check{x}_3 \rangle} & \ddots & \vdots \\ \vdots & \vdots & \cdots & \frac{1}{\langle \check{x}_k, \check{x}_k \rangle} \end{bmatrix}$$

$$W = \begin{bmatrix} \langle x_1, x_1 \rangle & \langle x_2, x_1 \rangle & \cdots \\ \langle x_1, x_2 \rangle & \cdots & \cdots \\ \vdots & \ddots & \vdots \\ \langle x_1, x_k \rangle & \cdots & \cdots \end{bmatrix}$$

Найдем элемент  $a_{11}$  и  $a_{12}$  —  $(1, 1)$  и  $(1, 2)$  элементы матрицы  $M \cdot W$ :

$$a_{11} = \frac{\langle x_1, x_1 \rangle}{\langle \check{x}_1, \check{x}_1 \rangle} - \frac{\hat{\alpha}_2 \langle x_1, x_2 \rangle}{\langle \check{x}_1, \check{x}_1 \rangle} - \cdots - \frac{\hat{\alpha}_k \langle x_1, x_k \rangle}{\langle \check{x}_1, \check{x}_1 \rangle} = \frac{1}{\langle \check{x}_1, \check{x}_1 \rangle} \left( \langle x_1, x_1 \rangle - \hat{\alpha}_2 \langle x_1, x_2 \rangle - \cdots - \hat{\alpha}_k \langle x_1, x_k \rangle \right)$$

Воспользуемся двумя равенствами:

1.  $x_1 - (\hat{\alpha}_2 x_2 + \hat{\alpha}_3 x_3 + \cdots + \hat{\alpha}_k x_k) = \check{x}_1$
2.  $\langle \check{x}_i, x_i \rangle = \langle \check{x}_i, \check{x}_i \rangle$

Поэтому:

$$a_{11} = \frac{\langle x_1, \tilde{x}_1 \rangle}{\langle \tilde{x}_1, \tilde{x}_1 \rangle} = 1$$

Находим  $a_{12}$ :

$$a_{12} = \frac{1}{\langle \tilde{x}_1, \tilde{x}_1 \rangle} \left( \langle x_2, x_1 \rangle - \hat{\alpha}_2 \langle x_2, x_2 \rangle - \dots - \hat{\alpha}_k \langle x_2, x_k \rangle \right) = \frac{\langle x_2, \tilde{x}_1 \rangle}{\langle \tilde{x}_1, \tilde{x}_1 \rangle} = 0,$$

так как  $\langle x_2, \tilde{x}_1 \rangle = 0$ , потому что остаток от регрессии  $x_1$  на  $x_2, x_3, \dots, x_k$  ортогонален  $x_2, x_3, \dots, x_k$ . Аналогично можно найти все элементы этой матрицы. Таким образом, получили, что  $M \cdot W = I$ .  $\square$

**Итог:** если  $W \cdot (n-1)$  – выборочная ковариационная матрица  $X$ , то  $W^{-1} = M$ .

$$M = W^{-1} = \begin{bmatrix} \frac{1}{RSS_1} & -\frac{\hat{\alpha}_2}{RSS_1} & \dots & -\frac{\hat{\alpha}_k}{RSS_1} \\ -\frac{\hat{\beta}_1}{RSS_2} & \frac{1}{RSS_2} & -\frac{\hat{\beta}_3}{RSS_2} & \vdots \\ \frac{RSS_1}{RSS_2} & \frac{RSS_2}{RSS_2} & \frac{RSS_2}{RSS_2} & \vdots \\ -\frac{\hat{\gamma}_1}{RSS_3} & -\frac{\hat{\gamma}_2}{RSS_3} & \ddots & \vdots \\ \frac{RSS_3}{RSS_3} & \frac{RSS_3}{RSS_3} & \ddots & 1 \\ \vdots & \vdots & \dots & \frac{1}{RSS_k} \end{bmatrix} = \begin{bmatrix} \frac{1}{RSS_1} & -\frac{\hat{\beta}_1}{RSS_2} & -\frac{\hat{\gamma}_1}{RSS_3} & \dots \\ -\frac{\hat{\alpha}_2}{RSS_1} & \frac{1}{RSS_2} & -\frac{\hat{\gamma}_2}{RSS_3} & \vdots \\ \frac{RSS_1}{RSS_2} & \frac{RSS_2}{RSS_2} & \frac{RSS_2}{RSS_3} & \vdots \\ -\frac{\hat{\alpha}_3}{RSS_3} & -\frac{\hat{\beta}_3}{RSS_2} & \ddots & \vdots \\ \frac{RSS_3}{RSS_3} & \frac{RSS_2}{RSS_2} & \ddots & 1 \\ \vdots & \vdots & \dots & \frac{1}{RSS_k} \end{bmatrix}$$