

Конспектировали: Ирина Долгалева и Дарья Краснова

1. Свойства многомерного нормального распределения

Случайный вектор u имеет многомерное нормальное стандартное распределение

$$u = \begin{pmatrix} u_1 \\ u_2 \\ \vdots \\ u_n \end{pmatrix} \sim \mathcal{N}(0, I)$$

каждое $u_i \sim \mathcal{N}(0, 1)$ и независимы. Такой вектор удовлетворяет ряду аксиом.

Аксиомы: 1. В любом ортонормальном базисе закон распределения вектора u одинаковый

2. u_i — независимы

3. $\text{Var}(u_i) = 1$

⇓ Из этих аксиом следует два важных текстовых свойства нормального распределения.

Свойства: 1. Квадрат длины проекции вектора u на V ($\dim(V) = d$) имеет $\sim \chi_d^2$ распределение

2. Квадраты длин проекции на V и W независимы, если $V \perp W$.

2. t — распределение

Классическое определение.

Случайная величина T

$$T = \frac{z}{\sqrt{\frac{\gamma_k}{k}}}$$

где $z \sim \mathcal{N}(0, 1)$, $\gamma_k \sim \chi_k^2$, имеет t -распределение с k степенями свободы, где z, γ_k — независимы.

Геометрическое определение.

Рассмотрим V — одномерное линейное подпространство, задаваемое вектором единичной длины v и ортогональное ему подпространство W размерности k :


$$V = \text{Lin}(v), \dim(V) = 1$$

$$\|v\|=1$$

$$W = \text{Col}(X), \dim(W) = k$$

$$V \perp W$$

Пусть u — вектор пространства \mathbb{R}^n , $\hat{u}_V = z \cdot v$ — проекция u на V , \hat{u}_W — проекция u на W , \hat{u}_{W+V} — проекция u на $W \oplus V$




Тогда, случайная величина T

$$T = \frac{z}{\sqrt{\frac{\|\hat{u}_W\|^2}{\dim(W)}}} = \operatorname{tg} \alpha \cdot \sqrt{\dim(W)} \sim t(k)$$

имеет t -распределение с k степенями свободы, где α — угол между \hat{u}_W и \hat{u}_{V+W} .

Рассмотрим подпространство $V + W$:



v — нормаль (единичной длины) к $W \Rightarrow v \perp W$

\hat{u}_W — проекция вектора u на W ; $\dim(W) = k \Rightarrow \|\hat{u}_W\|^2 \sim \chi_k^2$

Получаем эквивалентные определения.

3. \mathcal{F} – распределение

Классическое определение.

Случайная величина F

$$F = \frac{\gamma_a/a}{\gamma_b/b} \sim \mathcal{F}_{a,b},$$

имеет \mathcal{F} – распределение с (a, b) степенями свободы, где $\gamma_a \sim \chi_a^2$, $\gamma_b \sim \chi_b^2$ и γ_a, γ_b независимы.

Геометрическое определение.


Рассмотрим V – линейное подпространство размерности a и ортогональное ему подпространство W размерности b :

$$\dim(V) = a, \quad \dim(W) = b$$

$$V \perp W$$

$$\dim(V) + \dim(W) \leq n \text{ все в } \mathbb{R}^n$$

Пусть u – вектор пространства \mathbb{R}^n , $u \sim \mathcal{N}(0, I)$. Тогда \hat{u}_V – проекция u на V , \hat{u}_W – проекция вектора u на W , \hat{u}_{W+V} – проекция u на $W \oplus V$



Тогда, случайная величина F

$$F = \frac{\|\hat{u}_V\|^2 / \dim(V)}{\|\hat{u}_W\|^2 / \dim(W)} = \operatorname{tg}^2 \alpha \cdot \frac{\dim(W)}{\dim(V)} \sim \mathcal{F}(\dim(V), \dim(W)) = \mathcal{F}(a, b)$$

имеет \mathcal{F} – распределение с $(\dim(V), \dim(W))$ степенями свободы, где α – угол между \hat{u}_W и \hat{u}_{W+V}

$$\hat{u}_V - \text{проекция } u \text{ на } V; \dim(V) = a \Rightarrow \|\hat{u}_V\|^2 \sim \chi_a^2$$

$$\hat{u}_W - \text{проекция } u \text{ на } W; \dim(W) = b \Rightarrow \|\hat{u}_W\|^2 \sim \chi_b^2$$

Получаем эквивалентные определения.

Заметим, что t -статистика – это частный случай \mathcal{F} -статистики:

$$T^2 = F, \quad \dim(V) = a = 1$$

4. Связь \mathcal{F} распределения и эконометрических моделей

Теорема. Рассмотрим задачу регрессии и предположим:

1. Предполагаем $y = X\beta + u$.

2. Оцениваем:

а) длинную модель $\hat{y}^L = X\hat{\beta}^L$ (верная модель)

$$\min_{\hat{\beta}^L} \sum_{i=1}^n (y_i - \hat{y}_i^L)^2$$

б) короткую модель $\hat{y}^S = X\hat{\beta}^S$ (считаем, что последние d коэффициента — нулевые)

$$\min_{\hat{\beta}^S} \sum_{i=1}^n (y_i - \hat{y}_i^S)^2$$

$$\hat{\beta}_k = \hat{\beta}_{k-1} = \dots = \hat{\beta}_{k-d+1} = 0$$

3. Стандартные предпосылки

а) X — полного ранга, случайная

б) $u \sim \mathcal{N}(0, \sigma^2 I) \quad \equiv \quad u_i \sim \mathcal{N}(0, \sigma^2), u_i$ — независимы

4. Проверяем гипотезу

H_0 : Верна короткая модель

H_A : Короткая модель не верна

То,

$$1. \frac{RSS_L}{\sigma^2} \sim \chi_{n-k_L}^2$$

Если верна H_0 :

$$2. \frac{RSS_S - RSS_L}{\sigma^2} \sim \chi_{k_L - k_S}^2$$

3. RSS_L и $(RSS_S - RSS_L)$ — независимы


$$4. \frac{(RSS_S - RSS_L)/(k_L - k_S)}{RSS_L/(n - k_L)} \sim \mathcal{F}_{k_L - k_S, n - k_L}$$

Доказательство.

$$1. \hat{u} = (I - H)y = (I - H)(X\beta + u) = [(I - H)X\beta = 0] = (I - H)u \Rightarrow$$


\hat{u}_L — проекция вектора u на $\text{Col}^\perp(X_L)$, $\dim(\text{Col}^\perp(X_L)) = n - k_L \Rightarrow$

$RSS_L = \|\hat{u}_L\|^2$ — квадрат длины проекции u на $(n - k_L)$ -мерное подпространство



2. Теперь дополнительно предположим, что еще верна короткая модель (опускаем регрессоры, отвечающие за нулевые компоненты)

$$X = \begin{bmatrix} 1 & x_1 & z_1 & q_1 & w_1 \\ 1 & x_2 & z_2 & q_2 & w_2 \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ 1 & x_n & z_n & q_n & w_n \end{bmatrix} \Rightarrow X_S = \begin{bmatrix} 1 & x_1 & z_1 \\ 1 & x_2 & z_2 \\ \vdots & \vdots & \vdots \\ 1 & x_n & z_n \end{bmatrix}$$



$$RSS_S - RSS_L = \|\hat{u}_S\|^2 - \|\hat{u}_L\|^2 = \|\hat{y}_S - \hat{y}_L\|^2 = \sum_{i=1}^n (\hat{y}_i^S - \hat{y}_i^L)^2$$

$(\hat{y}_i^S - \hat{y}_i^L)$ – проекция y на $\text{Col } X_L \cap \text{Col}^\perp X_S$ (ортогональное дополнение X_S в подпространстве X_L)

$$\dim(\text{Col } X_L \cap \text{Col}^\perp X_S) = \dim(\text{Col } X_L) - \dim(\text{Col}^\perp X_S) = k_L - k_S \Rightarrow$$

$$\frac{RSS_S - RSS_L}{\sigma^2} \sim \chi_{k_L - k_S}^2$$

3. RSS_L и $(RSS_S - RSS_L)$ – независимы, поскольку они ортогональны

$$4. \frac{(RSS_S - RSS_L)/(\sigma^2(k_L - k_S))}{RSS_L/(\sigma^2(n - k_L))} = \frac{(RSS_S - RSS_L)/(k_L - k_S)}{RSS_L/(n - k_L)} \sim \mathcal{F}_{k_L - k_S, n - k_L}$$

□

5. Матрица-мать всех регрессий

Пусть дана матрица X :

$$X = \begin{bmatrix} \vdots & \vdots & \vdots & \vdots \\ x_1 & x_2 & \vdots & x_k \\ \vdots & \vdots & \vdots & \vdots \end{bmatrix};$$

Она состоит из центрированных векторов-столбцов x_j таких, что $\bar{x}_j = 0$ и $\sum_{i=1}^n x_{ij} = 0$. Тогда матрицы W и M определяются как:

$$W = X^T X; M = W^{-1}$$

Что же находится в матрице M ?

Построим регрессию x_1 на x_1, x_2, \dots, x_k . Тогда:

$$\hat{x}_1 = \hat{\alpha}_2 x_2 + \hat{\alpha}_3 x_3 + \dots + \hat{\alpha}_k x_k$$


$$\tilde{x}_1 = x_1 - (\hat{\alpha}_2 x_2 + \hat{\alpha}_3 x_3 + \dots + \hat{\alpha}_k x_k)$$

Упражнение: доказать, что:

$$\begin{cases} \langle \tilde{x}_1, x_2 \rangle = 0 \\ \langle \tilde{x}_1, x_3 \rangle = 0 \\ \vdots \\ \langle \tilde{x}_1, x_k \rangle = 0 \end{cases}$$

Доказательство.

Доказательство следует напрямую из картинки:



Вектор \tilde{x}_1 ортогонален линейной оболочке $\text{lin}(x_2, \dots, x_k)$, а значит ортогонален всем векторам, лежащим в ней. Получаем требуемое. □

Пользуясь этим знанием, посчитаем, чему равно $\langle \tilde{x}_1, x_1 \rangle$:

$$\langle \tilde{x}_1, x_1 \rangle = \langle \tilde{x}_1, \tilde{x}_1 + (\hat{\alpha}_2 x_2 + \hat{\alpha}_3 x_3 + \dots + \hat{\alpha}_k x_k) \rangle = \langle \tilde{x}_1, \tilde{x}_1 \rangle = \|\tilde{x}_1\|^2$$

Введем неожиданную нормировку:

$$\check{x}_1 = \frac{\tilde{x}_1}{\|\tilde{x}_1\|^2},$$

где \tilde{x}_1 — остаток от регрессии x_1 на x_2, x_3, \dots, x_k , $\|\tilde{x}_1\|^2$ — квадрат длины вектора остатков \tilde{x}_1 .

Почему была выбрана именно такая нормировка? Потому что хотели подобрать такую нормировку, двукратное применение которой к вектору v давало бы сам вектор v :

$$v \xrightarrow{g} \frac{v}{\|v\|^2}; g(g(v)) = v$$

Например,

$$\begin{pmatrix} 0 \\ 5 \end{pmatrix} \xrightarrow{g} \begin{pmatrix} 0 \\ \frac{1}{5} \end{pmatrix} \xrightarrow{g} \begin{pmatrix} 0 \\ 5 \end{pmatrix}$$

Покажем, что нормировка действительно удовлетворяет приведенному выше свойству для любого вектора v :

$$g(g(v)) = \frac{v/\|v\|^2}{\|v/\|v\|^2\|^2} = \frac{v/\|v\|^2}{1/\|v\|^2 \cdot \|v\|^2} = v$$

Аналогично, запишем формулу неожиданной нормировки для вектора остатков \tilde{x}_2 :

$$\check{x}_2 = \frac{\tilde{x}_2}{\|\tilde{x}_2\|^2},$$

где \tilde{x}_2 — остаток от регрессии x_2 на x_1, x_3, \dots, x_k , $\|\tilde{x}_2\|^2$ — квадрат длины вектора остатков \tilde{x}_2 .

Из векторов $\check{x}_1, \check{x}_2, \dots, \check{x}_k$ можно составить матрицу \check{x} :

$$\check{x} = \begin{bmatrix} \vdots & \vdots & \vdots & \vdots \\ \check{x}_1 & \check{x}_2 & \dots & \check{x}_k \\ \vdots & \vdots & \vdots & \vdots \end{bmatrix}$$

Таким образом, матрица \check{x} — это матрица странным образом отнормированных остатков в k регрессиях.

Как выглядит ковариационная матрица этих остатков? Для этого поймем, чему равна матрица $\check{x}^T \check{x}$.

Пусть c_{11} — $(1, 1)$ элемент матрицы $\check{x}^T \check{x}$, а c_{12} — $(1, 2)$ элемент. Тогда:

$$c_{11} = \langle \check{x}_1, \check{x}_1 \rangle = \|\check{x}_1\|^2 = \left\| \frac{\tilde{x}_1}{\|\tilde{x}_1\|^2} \right\|^2 = \frac{1}{\|\tilde{x}_1\|^2} = \frac{1}{RSS_1}$$

$$c_{12} = \langle \check{x}_1, \check{x}_2 \rangle = \frac{1}{\|\tilde{x}_1\|^2} \cdot \frac{1}{\|\tilde{x}_2\|^2} \langle \tilde{x}_1, \tilde{x}_2 \rangle$$

Для того, чтобы найти $\langle \tilde{x}_1, \tilde{x}_2 \rangle$, выпишем, чему они равны в явном виде:

$$\tilde{x}_1 = x_1 - (\hat{\alpha}_2 x_2 + \hat{\alpha}_3 x_3 + \dots + \hat{\alpha}_k x_k)$$

$$\tilde{x}_2 = x_2 - (\hat{\beta}_1 x_1 + \hat{\beta}_3 x_3 + \dots + \hat{\beta}_k x_k)$$

Тогда $\langle \tilde{x}_1, \tilde{x}_2 \rangle$ можно представить двумя способами (заменяя \tilde{x}_1 или \tilde{x}_2):

1. $\langle \tilde{x}_1, \tilde{x}_2 \rangle = \langle x_1 - (\hat{\alpha}_2 x_2 + \hat{\alpha}_3 x_3 + \dots + \hat{\alpha}_k x_k), \tilde{x}_2 \rangle = -\hat{\alpha}_2 \langle \tilde{x}_2 \rangle = -\hat{\alpha}_2 \|\tilde{x}_2\|^2$
2. $\langle \tilde{x}_1, \tilde{x}_2 \rangle = \langle \tilde{x}_1, x_2 - (\hat{\beta}_1 x_1 + \hat{\beta}_3 x_3 + \dots + \hat{\beta}_k x_k) \rangle = -\hat{\beta}_1 \langle \tilde{x}_1, \tilde{x}_1 \rangle = -\hat{\beta}_1 \|\tilde{x}_1\|^2$

При этом мы пользовались тем, что:

$$\tilde{x}_1 \perp x_2, x_3, \dots, x_k$$

$$\tilde{x}_2 \perp x_1, x_3, \dots, x_k$$

Вернемся к нахождению c_{12} :

$$c_{12} = \langle \tilde{x}_1, \tilde{x}_2 \rangle = \frac{1}{\|\tilde{x}_1\|^2} \cdot \frac{1}{\|\tilde{x}_2\|^2} \langle \tilde{x}_1, \tilde{x}_2 \rangle = \frac{-\hat{\beta}_1}{\|\tilde{x}_2\|^2} = \frac{-\hat{\alpha}_2}{\|\tilde{x}_1\|^2}$$

Таким образом, бесплатно получили следующее:

$$\frac{(\text{коэффициент при } x_2 \text{ в регрессии } x_1 \text{ на ост.})}{RSS_1} = \frac{(\text{коэффициент при } x_1 \text{ в регрессии } x_2 \text{ на ост.})}{RSS_2}$$

Упражнение: доказать, что $\tilde{x}^T X = I$.

Доказательство.

Для этого найдем $(1, 1)$ и $(1, 2)$ элементы матрицы $\tilde{x}^T X = I$:

$$b_{11} = \langle \tilde{x}_1, x_1 \rangle = \left\langle \frac{\tilde{x}_1}{\|\tilde{x}_1\|^2}, x_1 \right\rangle = \langle \tilde{x}_1, x_1 \rangle \cdot \frac{1}{\|\tilde{x}_1\|^2} = \langle \tilde{x}_1, \tilde{x}_1 \rangle \cdot \frac{1}{\|\tilde{x}_1\|^2} = 1$$

$$b_{12} = \langle \tilde{x}_1, x_2 \rangle = \langle \tilde{x}_1, x_2 \rangle \cdot \frac{1}{\|\tilde{x}_1\|^2} = 0$$

□

Упражнение: пусть

$$W = X^T X$$

$$M = \tilde{x}^T \tilde{x}$$

Доказать, что $M \cdot W = I$ (то есть $M = W^{-1}$).

Доказательство.

Из предыдущей части лекции известно, чему равны матрицы M и W :

$$M = \begin{bmatrix} 1 & -\hat{\alpha}_2 & -\hat{\alpha}_3 & \cdots \\ \frac{\langle \tilde{x}_1, \tilde{x}_1 \rangle}{\langle \tilde{x}_1, \tilde{x}_1 \rangle} & \frac{\langle \tilde{x}_1, \tilde{x}_1 \rangle}{\langle \tilde{x}_1, \tilde{x}_1 \rangle} & \frac{\langle \tilde{x}_1, \tilde{x}_1 \rangle}{\langle \tilde{x}_1, \tilde{x}_1 \rangle} & \cdots \\ -\hat{\beta}_1 & 1 & -\hat{\beta}_3 & \vdots \\ \frac{\langle \tilde{x}_2, \tilde{x}_2 \rangle}{\langle \tilde{x}_2, \tilde{x}_2 \rangle} & \frac{\langle \tilde{x}_2, \tilde{x}_2 \rangle}{\langle \tilde{x}_2, \tilde{x}_2 \rangle} & \frac{\langle \tilde{x}_2, \tilde{x}_2 \rangle}{\langle \tilde{x}_2, \tilde{x}_2 \rangle} & \vdots \\ -\hat{\gamma}_1 & -\hat{\gamma}_2 & \ddots & \vdots \\ \frac{\langle \tilde{x}_3, \tilde{x}_3 \rangle}{\langle \tilde{x}_3, \tilde{x}_3 \rangle} & \frac{\langle \tilde{x}_3, \tilde{x}_3 \rangle}{\langle \tilde{x}_3, \tilde{x}_3 \rangle} & \ddots & \vdots \\ \vdots & \vdots & \cdots & \frac{1}{\langle \tilde{x}_k, \tilde{x}_k \rangle} \end{bmatrix}$$

$$W = \begin{bmatrix} \langle x_1, x_1 \rangle & \langle x_2, x_1 \rangle & \cdots \\ \langle x_1, x_2 \rangle & \cdots & \cdots \\ \vdots & \ddots & \vdots \\ \langle x_1, x_k \rangle & \cdots & \cdots \end{bmatrix}$$

Найдем элемент a_{11} и a_{12} — (1, 1) и (1, 2) элементы матрицы $M \cdot W$:

$$a_{11} = \frac{\langle x_1, x_1 \rangle}{\langle \tilde{x}_1, \tilde{x}_1 \rangle} - \frac{\hat{\alpha}_2 \langle x_1, x_2 \rangle}{\langle \tilde{x}_1, \tilde{x}_1 \rangle} - \cdots - \frac{\hat{\alpha}_k \langle x_1, x_k \rangle}{\langle \tilde{x}_1, \tilde{x}_1 \rangle} = \frac{1}{\langle \tilde{x}_1, \tilde{x}_1 \rangle} \left(\langle x_1, x_1 \rangle - \hat{\alpha}_2 \langle x_1, x_2 \rangle - \cdots - \hat{\alpha}_k \langle x_1, x_k \rangle \right)$$

Воспользуемся двумя равенствами:

1. $x_1 - (\hat{\alpha}_2 x_2 + \hat{\alpha}_3 x_3 + \cdots + \hat{\alpha}_k x_k) = \tilde{x}_1$
2. $\langle \tilde{x}_i, x_i \rangle = \langle \tilde{x}_i, \tilde{x}_i \rangle$

Поэтому:

$$a_{11} = \frac{\langle x_1, \tilde{x}_1 \rangle}{\langle \tilde{x}_1, \tilde{x}_1 \rangle} = 1$$

Находим a_{12} :

$$a_{12} = \frac{1}{\langle \tilde{x}_1, \tilde{x}_1 \rangle} \left(\langle x_2, x_1 \rangle - \hat{\alpha}_2 \langle x_2, x_2 \rangle - \cdots - \hat{\alpha}_k \langle x_2, x_k \rangle \right) = \frac{\langle x_2, \tilde{x}_1 \rangle}{\langle \tilde{x}_1, \tilde{x}_1 \rangle} = 0,$$

так как $\langle x_2, \tilde{x}_1 \rangle = 0$, потому что остаток от регрессии x_1 на x_2, x_3, \dots, x_k ортогонален x_2, x_3, \dots, x_k . Аналогично можно найти все элементы этой матрицы. Таким образом, получили, что $M \cdot W = I$. \square

Итог: если $W \cdot (n-1)$ — выборочная ковариационная матрица X , то $W^{-1} = M$:

$$M = W^{-1} = \begin{bmatrix} 1 & -\hat{\alpha}_2 & \cdots & -\hat{\alpha}_k \\ \frac{RSS_1}{RSS_1} & \frac{RSS_1}{RSS_1} & \cdots & \frac{RSS_1}{RSS_1} \\ -\hat{\beta}_1 & 1 & -\hat{\beta}_3 & \vdots \\ \frac{RSS_2}{RSS_2} & \frac{RSS_2}{RSS_2} & \frac{RSS_2}{RSS_2} & \vdots \\ -\hat{\gamma}_1 & -\hat{\gamma}_2 & \ddots & \vdots \\ \frac{RSS_3}{RSS_3} & \frac{RSS_3}{RSS_3} & \ddots & \vdots \\ \vdots & \vdots & \cdots & \frac{1}{RSS_k} \end{bmatrix} = \begin{bmatrix} 1 & -\hat{\beta}_1 & -\hat{\gamma}_1 & \cdots \\ \frac{RSS_1}{RSS_1} & \frac{RSS_2}{RSS_2} & \frac{RSS_3}{RSS_3} & \cdots \\ -\hat{\alpha}_2 & 1 & -\hat{\gamma}_2 & \vdots \\ \frac{RSS_1}{RSS_1} & \frac{RSS_2}{RSS_2} & \frac{RSS_3}{RSS_3} & \vdots \\ -\hat{\alpha}_3 & -\hat{\beta}_3 & \ddots & \vdots \\ \frac{RSS_3}{RSS_3} & \frac{RSS_2}{RSS_2} & \ddots & \vdots \\ \vdots & \vdots & \cdots & \frac{1}{RSS_k} \end{bmatrix}$$